


Documentación de arquitectura: Implementación de Datalake para seguimiento de libros y géneros de libros más populares

Resumen ejecutivo

Este documento describe la arquitectura de datos técnica implementada con AWS para MISAMO inc. El objetivo principal es ofrecer una visión clara del flujo de datos a través de la solución, desde la capa más básica, donde se ingestan del origen, hasta la más compleja, donde se consumen a través de un tablero visual.

Diagrama de arquitectura

La solución se basa en una arquitectura medallion, donde los datos se dividen en tres capas, bronce, donde se encuentran los datos crudos, silver, donde los datos ya han sido procesados y seleccionados y por último, gold, en donde se encuentran los datos que responden las preguntas de negocio. Para este caso específico, se ha decidido utilizar la infraestructura de AWS, esto por la versatilidad que ofrecen los servicios, como autoescalamiento o nula gestión de recursos, así como por el bajo costo frente a soluciones on-premise.



Stack tecnológico

Tecnología	Propósito
Python (BeautifulSoup, requests)	Escrapeo web, ingesta de datos
AWS Lambda, AWS Glue	Ejecución serverless
Amazon S3, Amazon RDS	Almacenamiento y consumo final
Amazon Bedrock	Resumen de opiniones
AWS step functions	Orquestación
AWS Event bridge	Creación de trabajos calendarizados
AWS Glue data catalog	Catálogos de datos y manejo de metadatos
Tableau	Consumo

Descripción de capas

Capa	Descripción de contenido	Tecnología
Bronze	Datos en formato JSON tal cual son recabados de la fuente. Información de los libros y sus opiniones. La información de los libros se guarda cuantas veces salga en el top populares.	AWS Lambda, Amazon S3
Silver	Datos en formato Parquet generados mediante IA para resumir opiniones capturando el sentimiento general. Solo se guarda	AWS Gluejob, AWS Glue Datacatalog, Amazon S3

	información del libro una vez. se guarda aparición del libro como año, semana, id de libro.	
Golden	Conteo de apariciones de géneros y libros en un número X de semanas. Se guarda el top 10 libros que han aparecido más y el top 20 géneros.	AWS Gluejob, AWS Glue Datacatalog, Amazon RDS

Flujo de datos

1. Se dispara un trabajo calendarizado cada Domingo a las 18:00 GMT-6 mediante Event Bridge el cual tiene como objetivo la ejecución de una Step function, la cual:
 - a. Ejecuta el scraper en Lambda para recolectar información directamente de Goodreads y guarda esta información en la capa bronce como un JSON. Al terminar su ejecución, la función da como salida la semana y año del scrapeo.
 - b. Ejecuta el Glue job que consume como argumentos la semana y año del scrapeo. Este trabajo resume las opiniones de los usuarios acerca del libro usando un LLM proporcionado mediante Bedrock y registra la aparición del libro esta semana y año. Toda la información generada se guarda en la capa bronce como un parquet.
2. Cuando sea solicitado por el cliente, se ejecuta el Glue job que transforma los datos de la capa Silver a la capa Gold. Este trabajo tiene como objetivo contabilizar el número de apariciones de un Libro dentro de una ventana de tiempo X (especificada por el cliente); asimismo, se genera un conteo de apariciones de géneros.
3. La información creada puede ser cargada a algún software de BI (Tableau o power BI) para ser analizada, aunque es tan sencilla que no sería tan necesario. sin embargo, es posible. Un ejemplo se muestra a continuación.

Géneros más populares las últimas 6 semanas

